Tratamento e Mineração de Dados

Naive Bayes e Florestas Randômicas

Marcos Pereira

6 de maio de 2020

$$\mathbf{R} = \overset{\text{classe}}{\left[\begin{array}{ccc|c} x_1 & x_2 & x_3 & y_1 \\ x_1' & x_2' & x_3' & y_2 \\ x_1 & x_2' & x_3 & y_3 \end{array}\right]}\Bigg\}_{\text{instâncias}} = \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \\ \mathbf{x}_3 \end{bmatrix}$$

Desse modo os vetores instâncias são os vetores $\mathbf{x}_i$, é importante notar que as relações equivalem aos nossos data sets.

- Criar modelos genéricos;
- Evitar a criação de modelos superajustados (overfiting);
  - Hipótese apresenta resultados específicos.
  - Modelo ajusta-se aos dados de treinamento mas não é eficaz para novos exemplos.[1]
- Treinar o modelo e testá-lo. Como?


DADOS


TREINO
DADOS


Algoritmo
DADOS
TREINO
CLASSIFICADOR

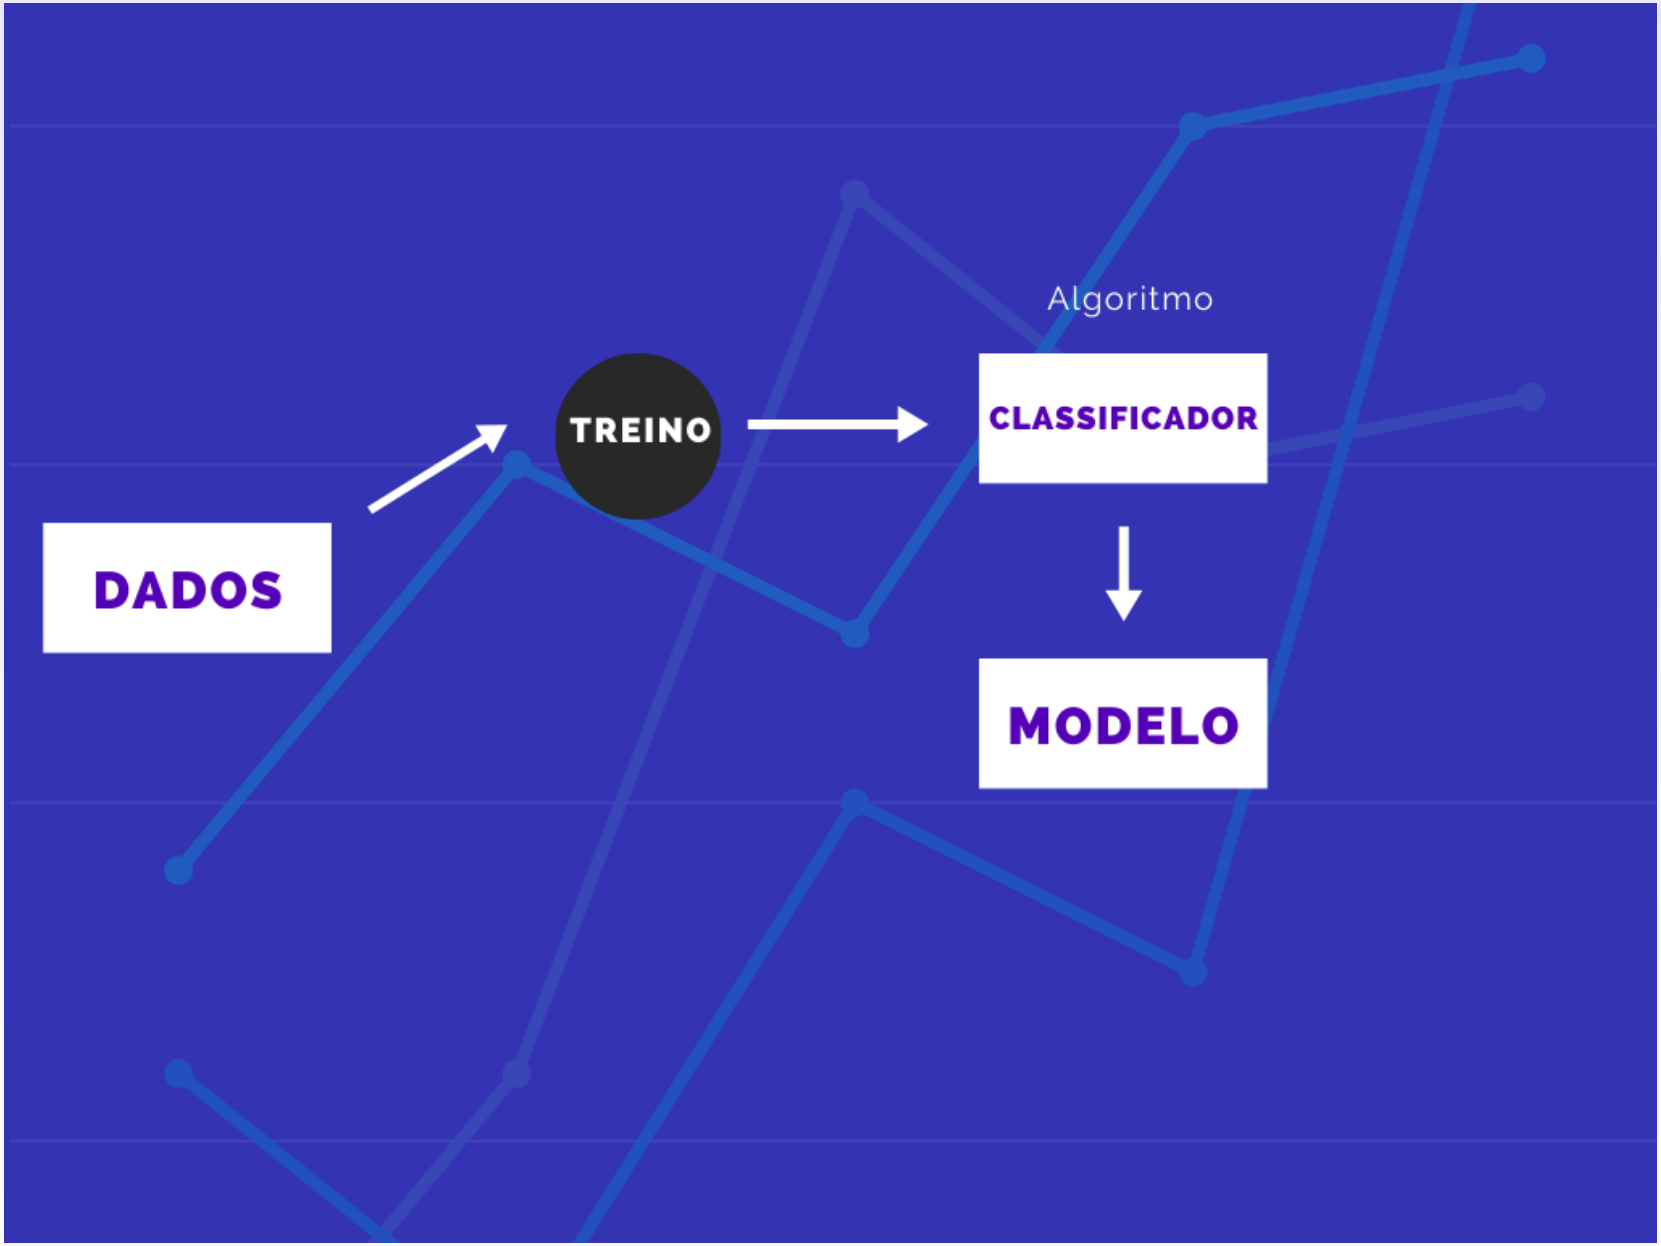
Algoritmo
DADOS
TREINO
CLASSIFICADOR
MODELO

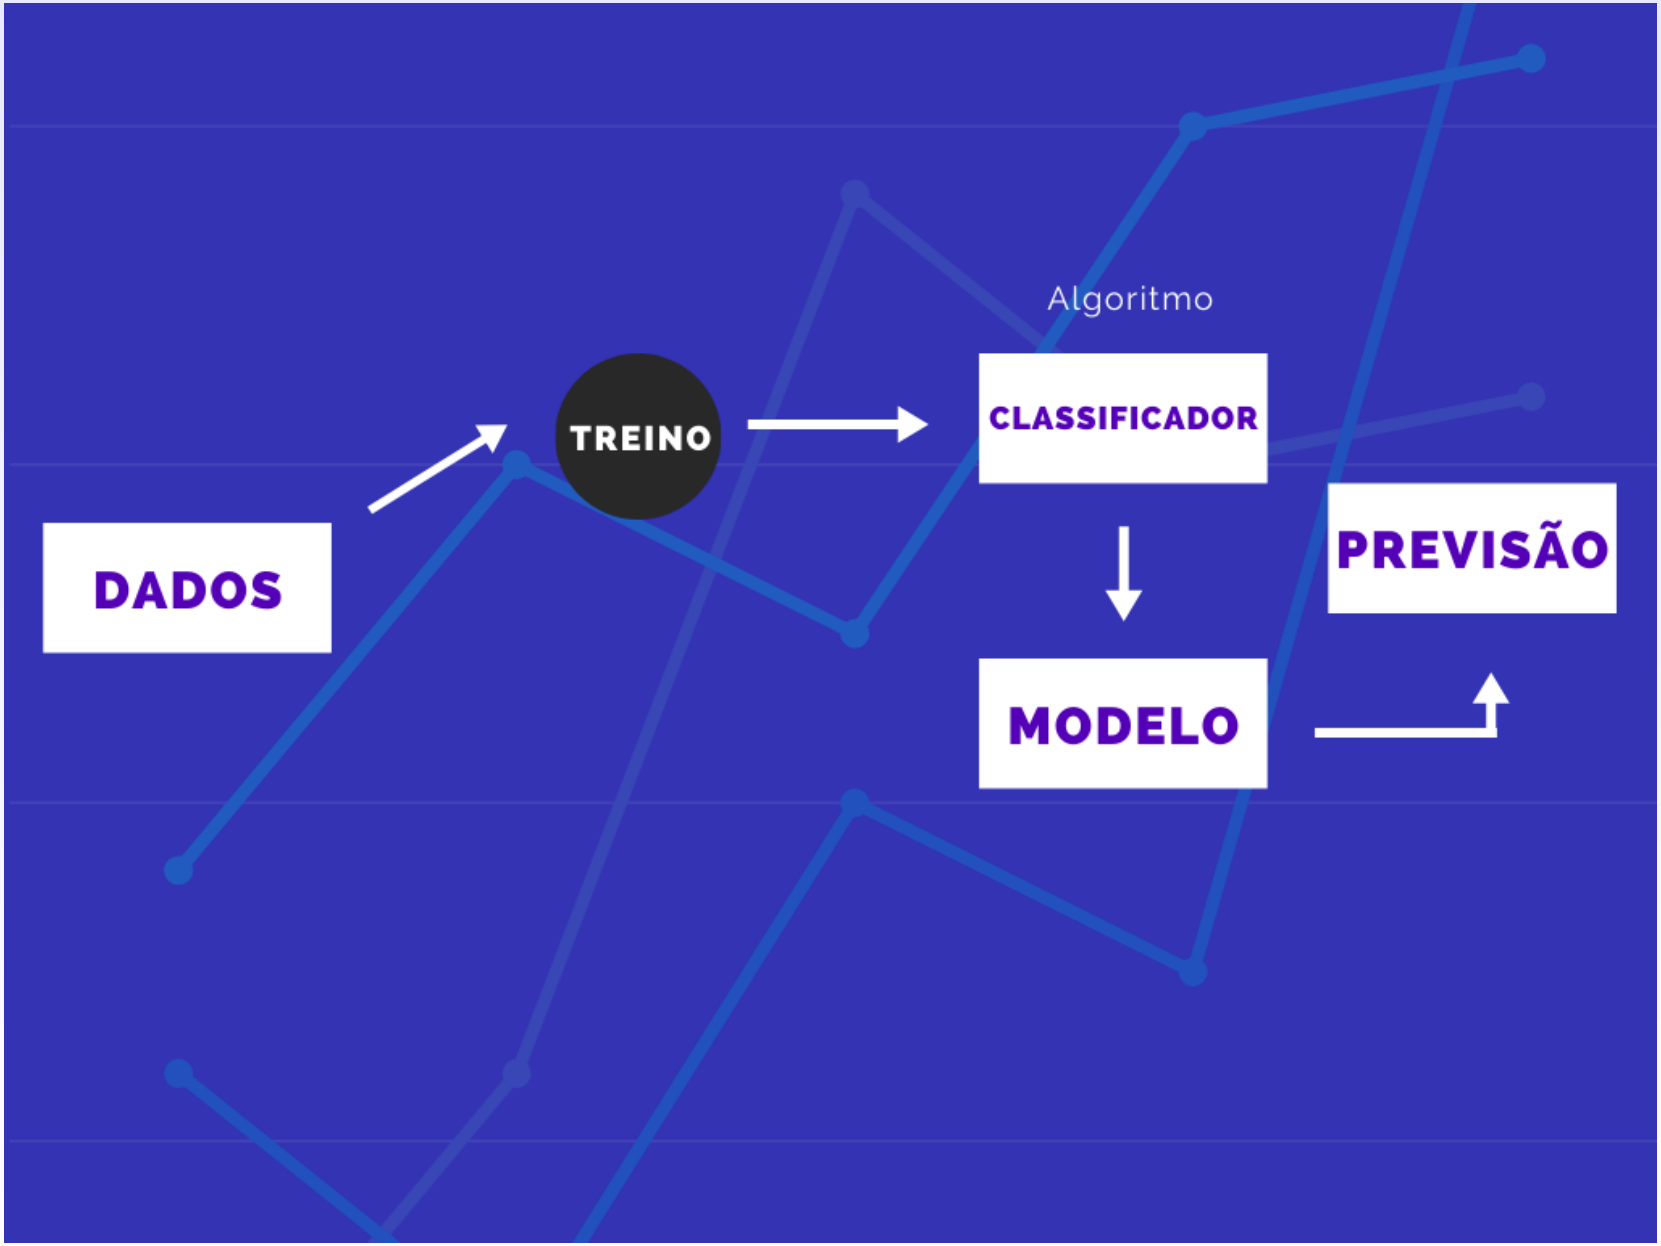
Algoritmo
DADOS
TREINO
CLASSIFICADOR
MODELO
PREVISÃO

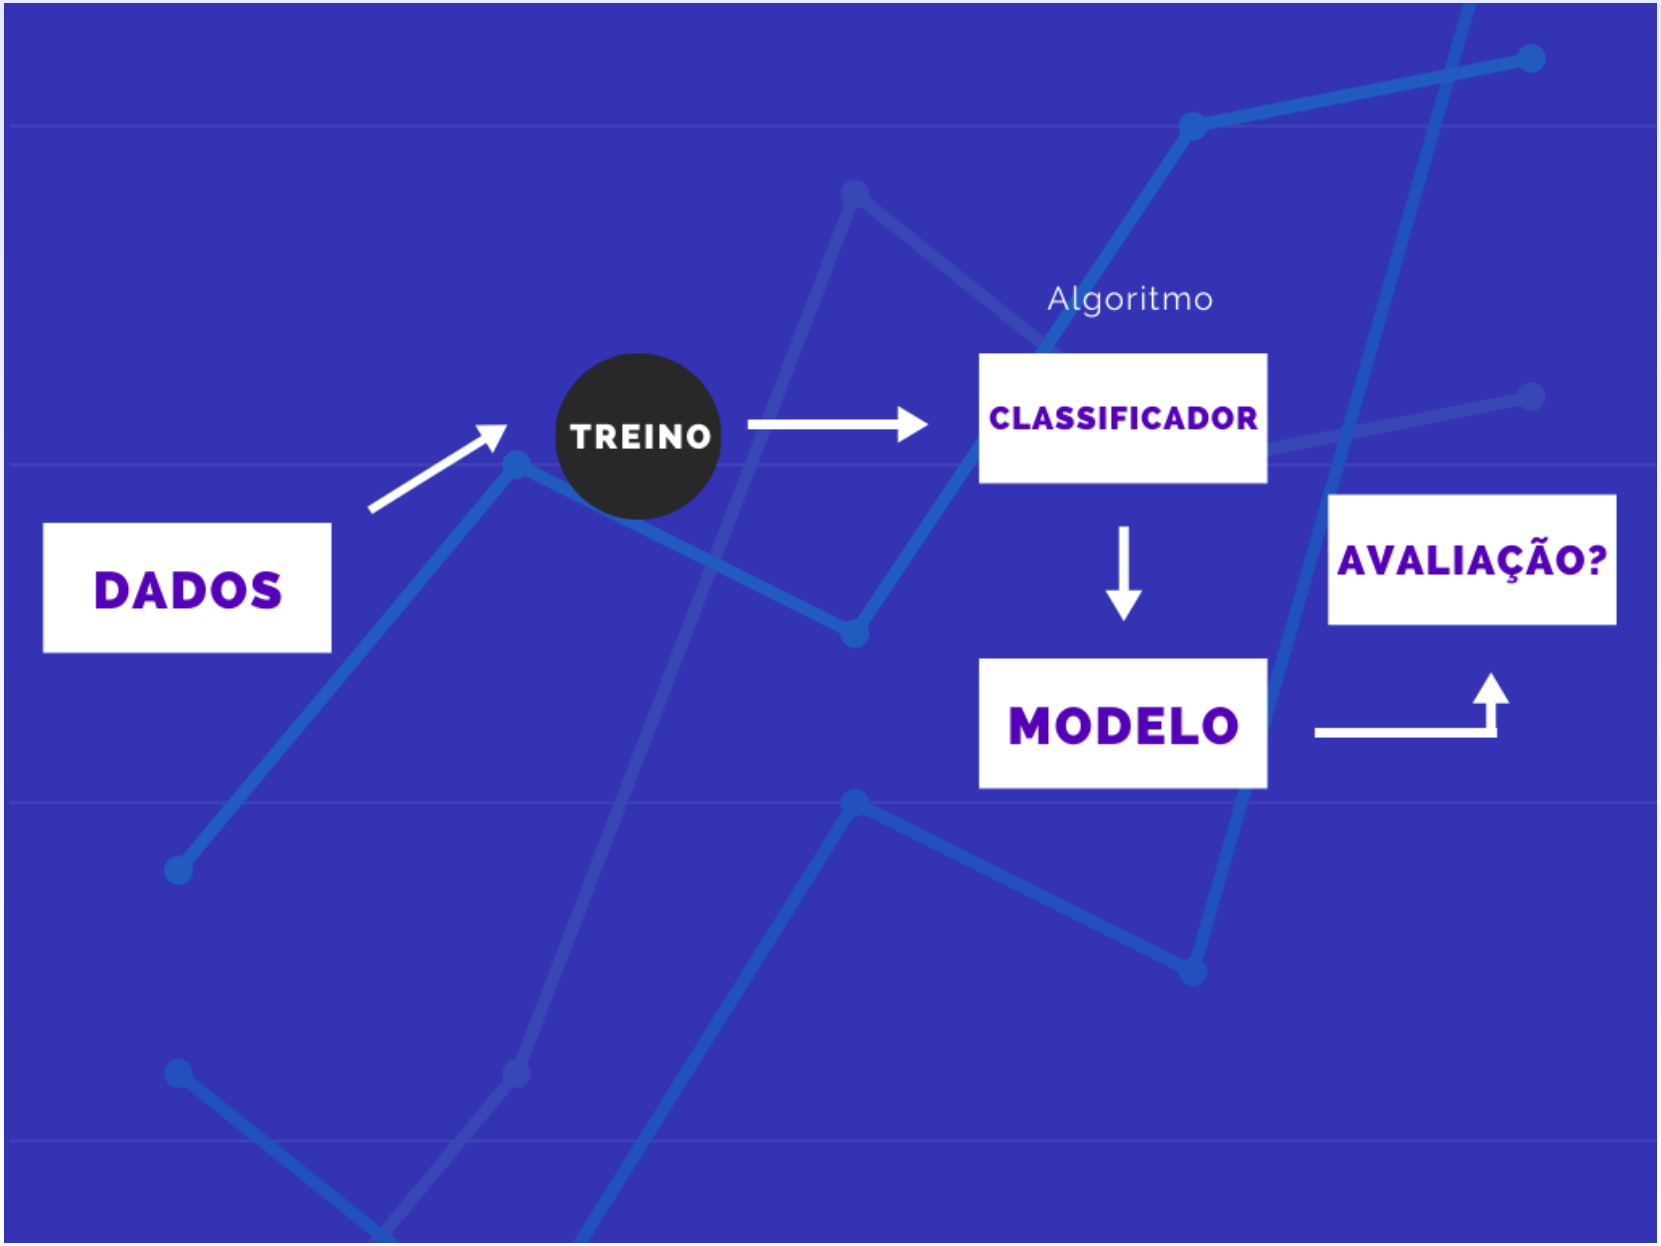
Algoritmo
DADOS
TREINO
CLASSIFICADOR
MODELO
AVALIAÇÃO?

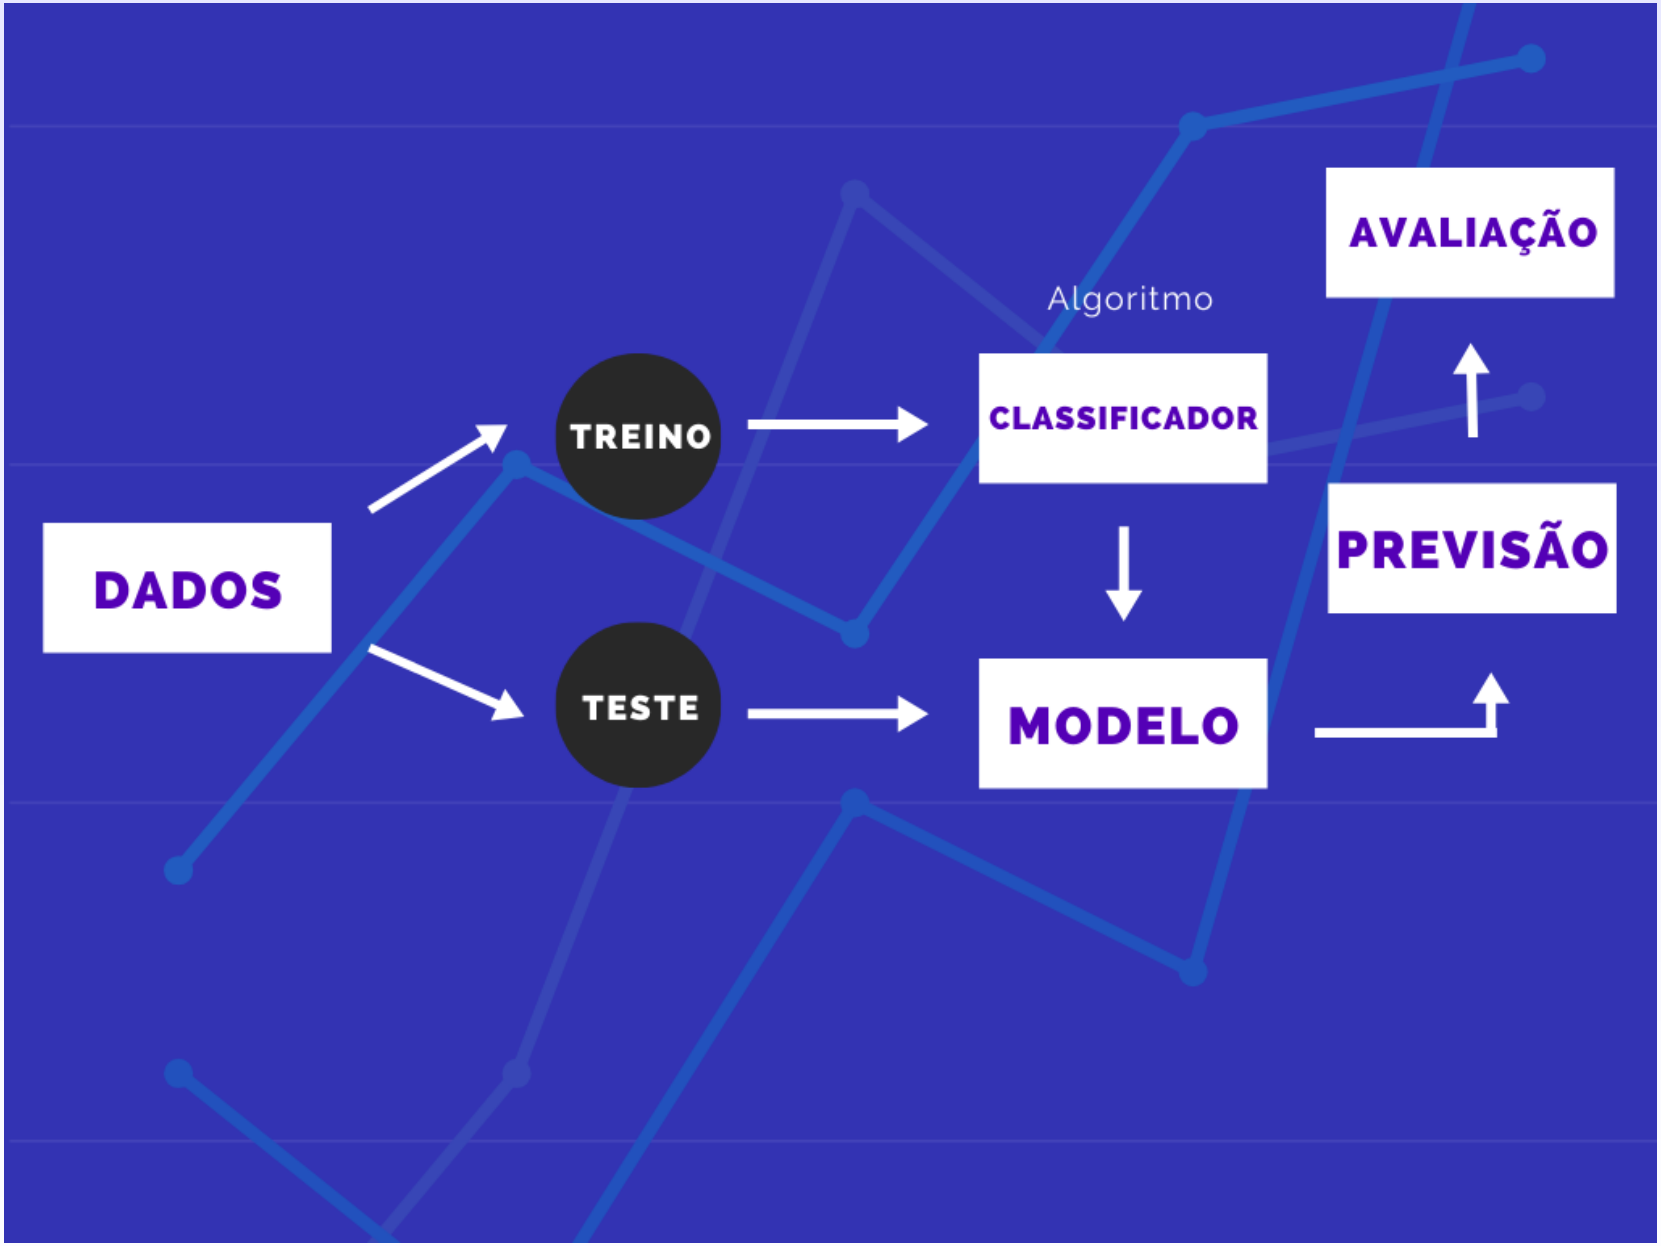
DADOS
TREINO
TESTE
Algoritmo
CLASSIFICADOR
MODELO
AVALIAÇÃO
PREVISÃO

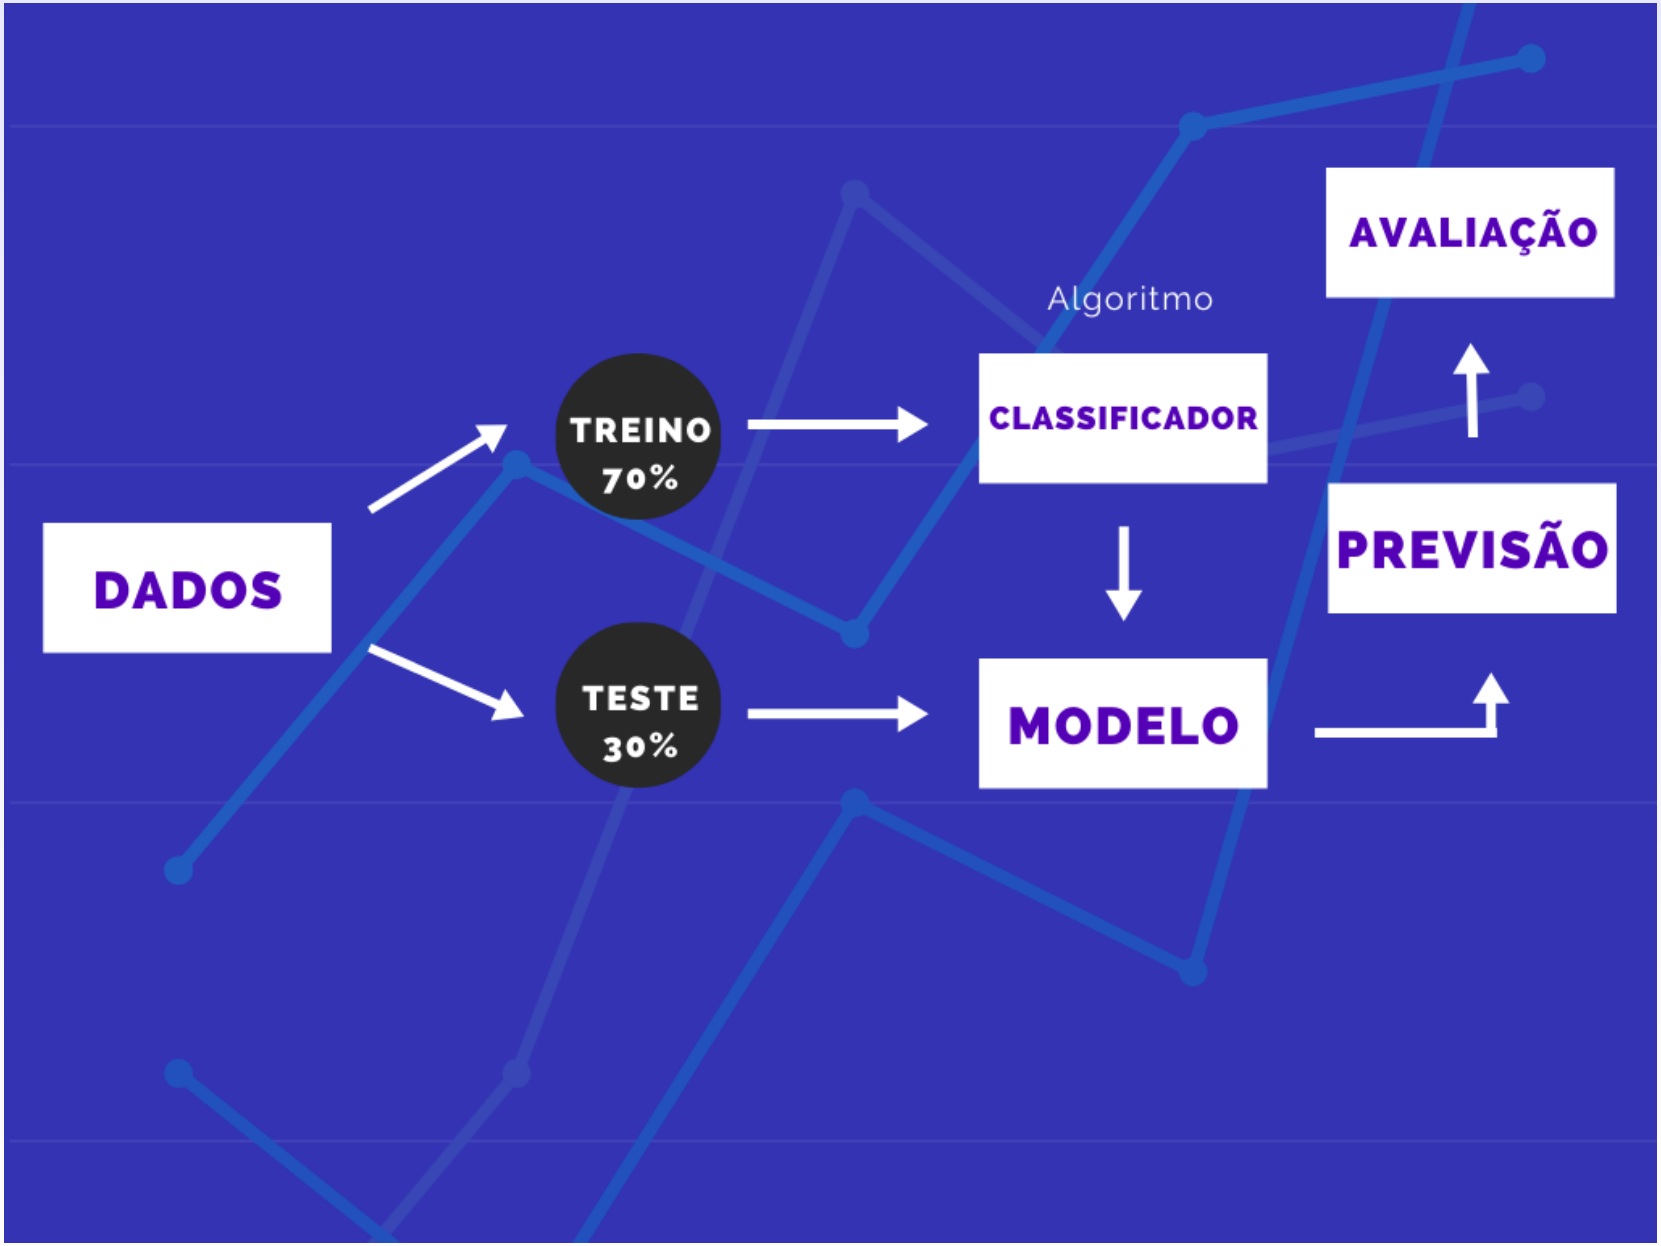
DADOS
TREINO 70%
TESTE 30%
Algoritmo
CLASSIFICADOR
MODELO
AVALIAÇÃO
PREVISÃO

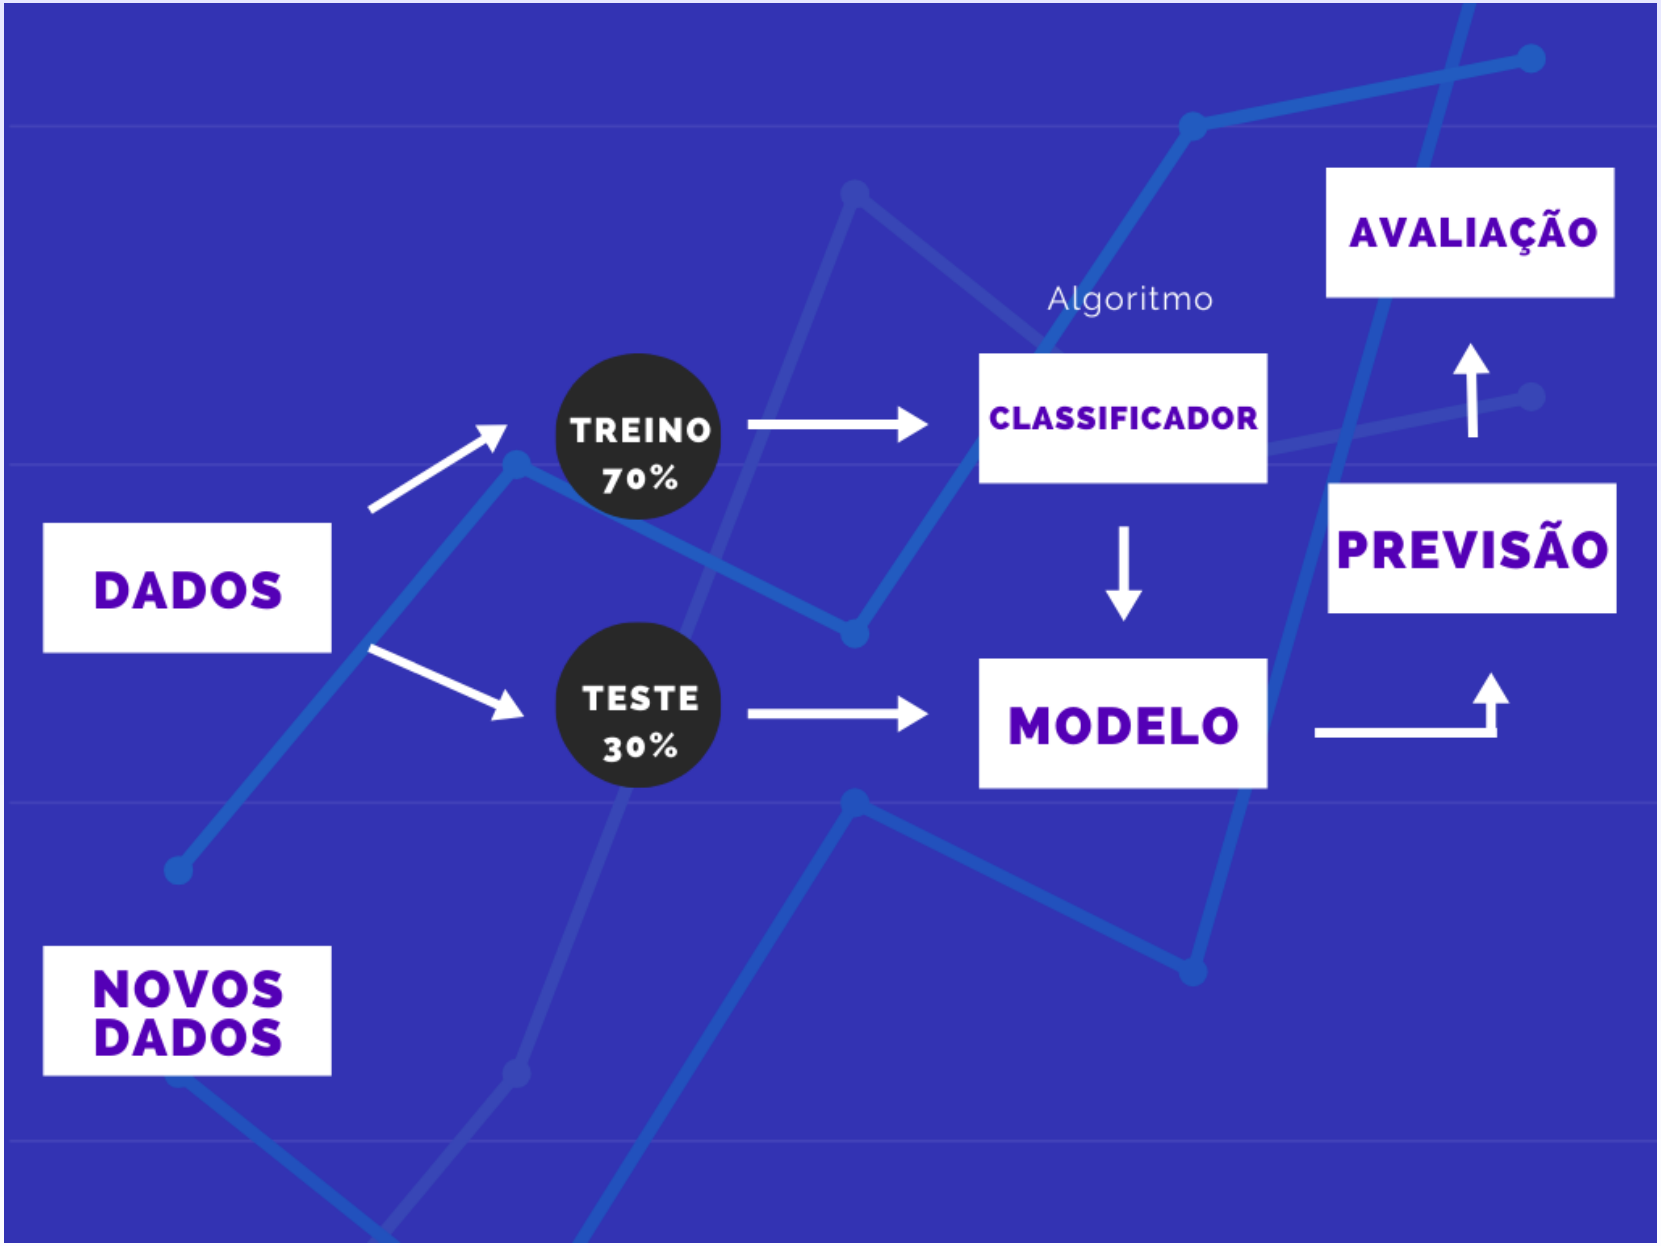
DADOS
TREINO 70%
TESTE 30%
Algoritmo
CLASSIFICADOR
MODELO
AVALIAÇÃO
PREVISÃO
NOVOS DADOS

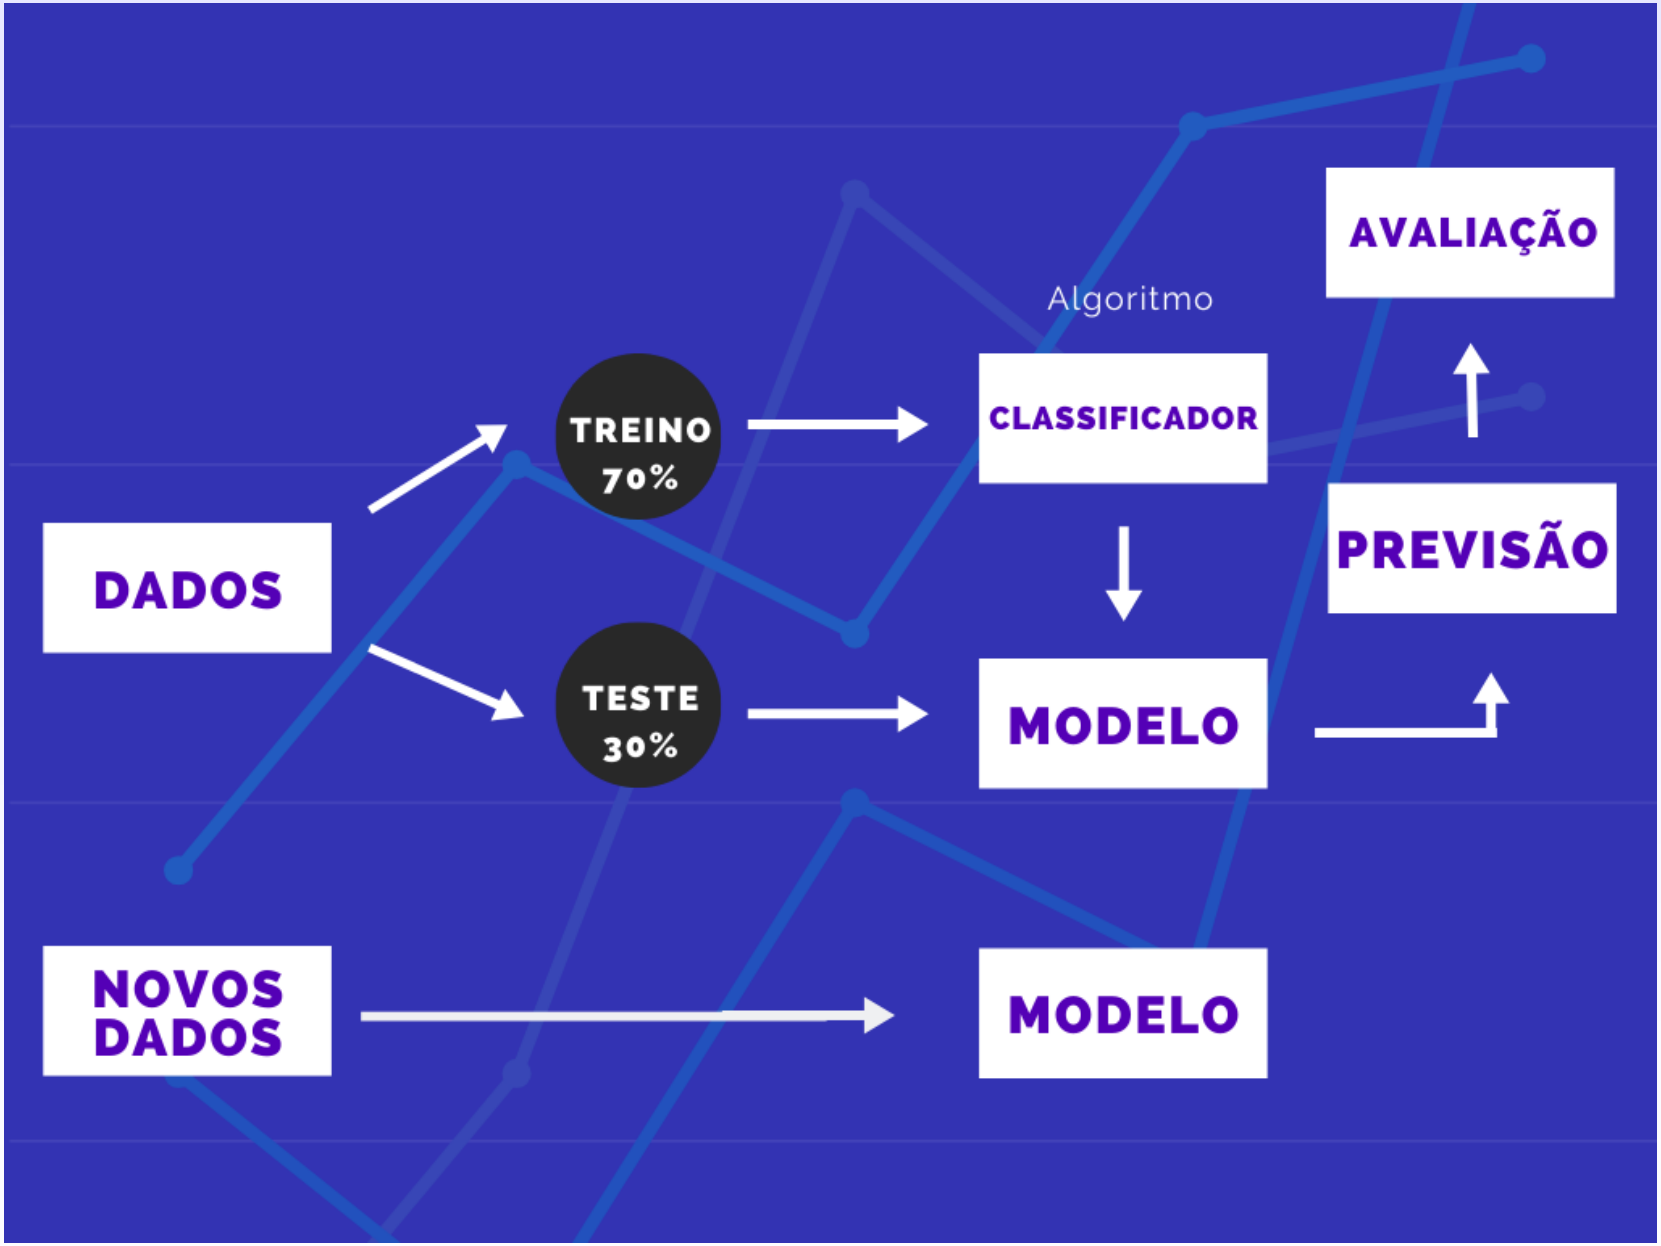
DADOS
TREINO 70%
TESTE 30%
Algoritmo
CLASSIFICADOR
MODELO
AVALIAÇÃO
PREVISÃO
NOVOS DADOS
MODELO

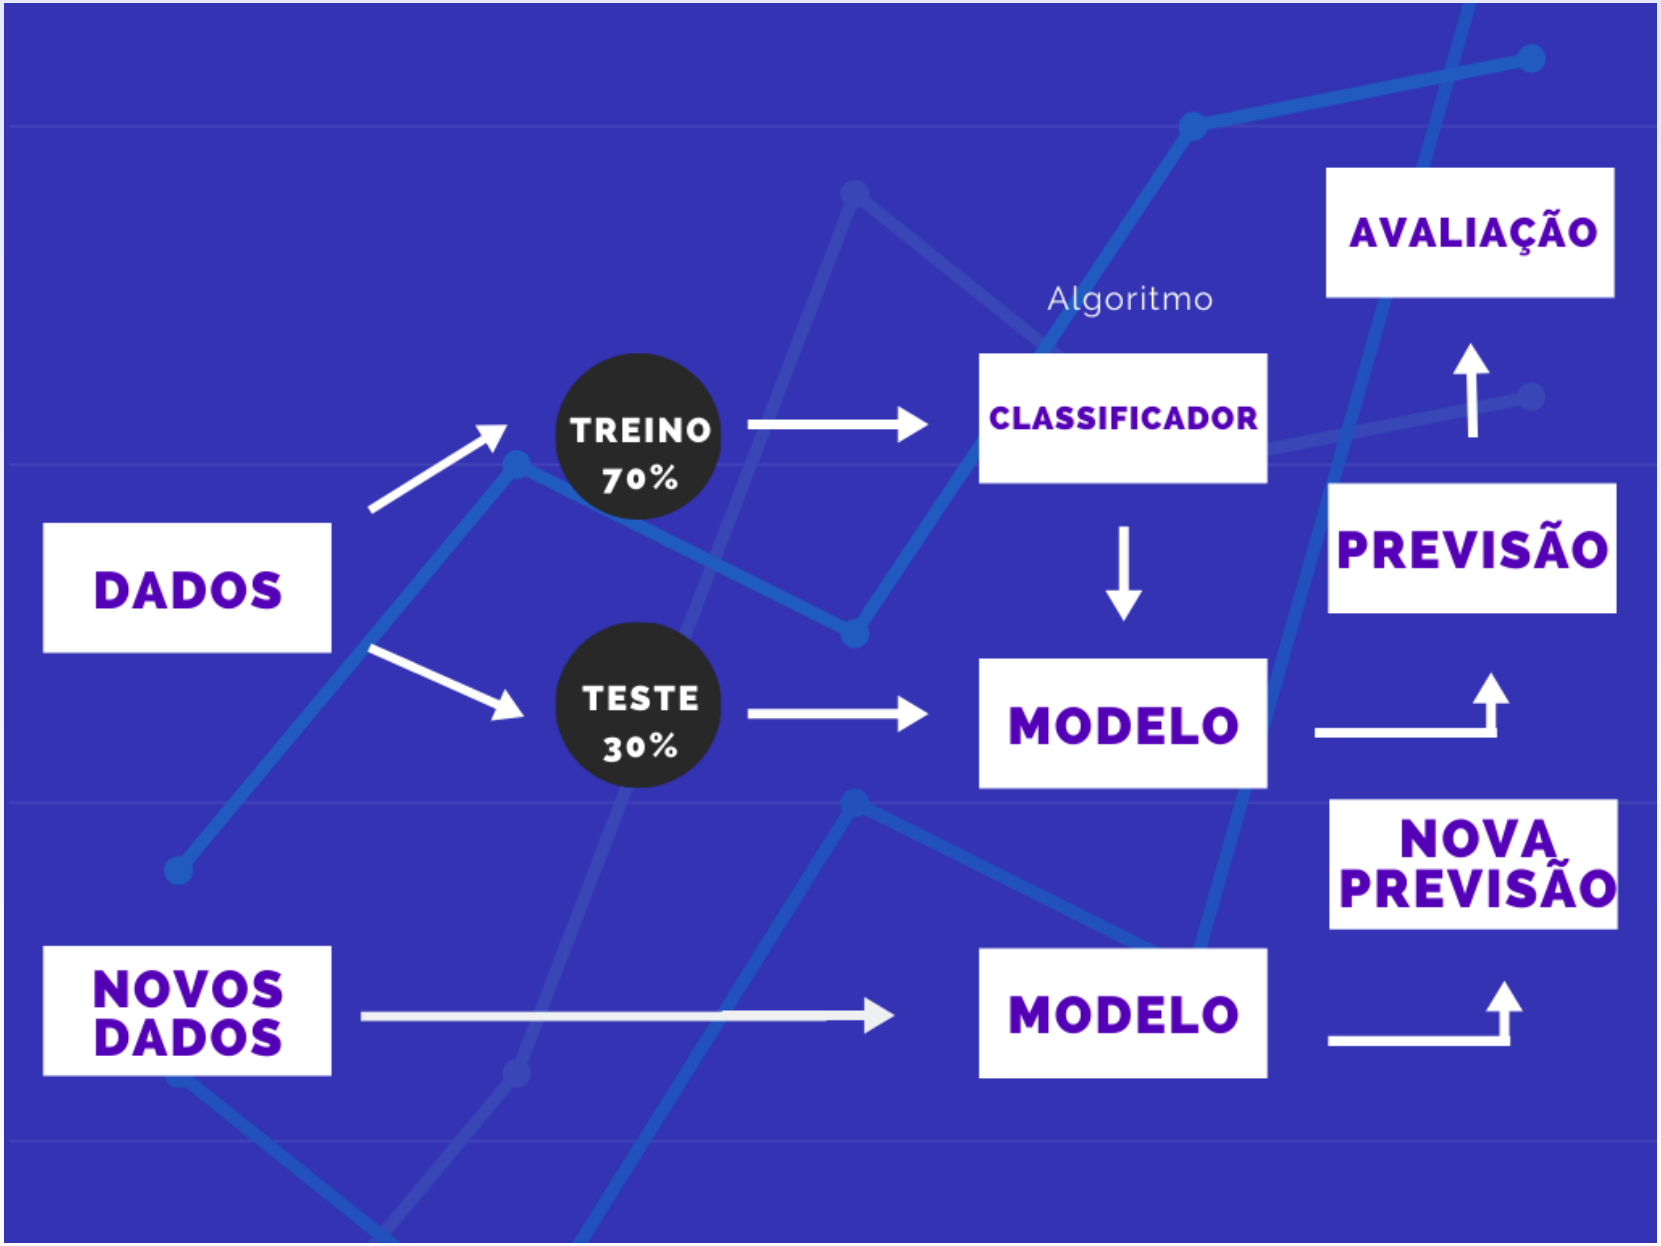
DADOS
TREINO 70%
TESTE 30%
Algoritmo
CLASSIFICADOR
MODELO
AVALIAÇÃO
PREVISÃO
NOVA PREVISÃO
NOVOS DADOS
MODELO

- Conjunto de Algoritmos de aprendizado supervisionado;
- Paradigma estatístico:
  - Avaliação de hipóteses pela máxima verossimilhança (inferência Bayesiana).
- Teorema de Bayes[1]:

$$P\left(y|x_1, x_2, \cdots, x_n\right) = \prod_{i=1}^{n} \frac{P(y)P(x_i|y)}{P(x_i)} \tag{1}$$

$$\equiv \frac{P(y)\left(P(x_1|y)P(x_2|y)\cdots P(x_n|y)\right)}{P(x_1)P(x_2)\cdots P(x_n)}$$

- A probabilidade A Priori $P(\mathbf{x}) \in \mathbb{R}$ é constante, e utilizaremos a seguinte regra de classificação:

$$P(y|\mathbf{x}) \propto \prod_{i=1}^{n} P(y)P(x_i|y) \tag{2}$$

[1] O símbolo $\prod$ representa um produtório.

- Máxima Probabilidade A Posteriori para realizar predição de dados:

$$Y = \arg\max_{y} \prod_{i=1}^{n} P(y)P(x_i|y) \tag{3}$$

- Y =Probabilidade de y posteriori condicionada a $\mathbf{x}$
- Naive Bayes Gaussiano. Verossimilhança[2]:

$$P\left(x_i|y\right) = \frac{1}{\sqrt{2\pi}\sigma_y} \exp\left[-\left(\frac{x_i - \mu_y}{\sqrt{2}\sigma_y}\right)^2\right]$$

- Predição de dados:

$$Y = \arg\max_{y} P(y) \exp\left[-\frac{1}{2\sigma_y^2} \sum_{i=1}^{n} \left(x_i - \mu_y\right)^2\right]$$

- Em alguns casos os atributos não são condicionalmente independentes;

- Ensemble Learning: Combinar predições de vários métodos de classificação a fim de otimizar a predição dos dados;
- Realizaremos a combinação de vários classificadores independentes, o resultado é a média das predições obtidas;
- Floresta Randômica: Baseado em árvores de decisão, consiste em criarmos n árvores de decisão, treiná-las e obter a resposta de cada uma delas;
- Várias fontes de aleatoriedade reduzem a variância do "forest estimator", árvores de decisão sozinhas apresentam uma alta variância e consquentemente produzem modelos superajustados;

- Implementação do Método será realizado utilizando o Sklearn [2];
- Tratar dados → Pré processamento de dados → Treinamento → Avaliação → Predição → Otimização

Importação das bibliotecas e métodos:

```
import numpy as np
import pandas as pd

from datetime import datetime

import matplotlib.pyplot as plt

import seaborn as sns
```

em seguida os algoritmos e métodos de Machine Learning do sklearn:

```
#ML

from sklearn.preprocessing import LabelEncoder,
OneHotEncoder

from sklearn.compose import make_column_transformer
```

```
#Divisão dados de treino e teste
from sklearn.model_selection import train_test_split

#Florestas Aleatórias

from sklearn.ensemble import RandomForestClassifier


#Método de Naive Bayes
from sklearn.naive_bayes import GaussianNB

#Taxa de acerto e de erro

from sklearn.metrics import accuracy_score

#Visualizaremos a matriz de confusão através da
#Yellow Brick
from yellowbrick.classifier import ConfusionMatrix
```

Começamos o tratamento dos dados, importando o dataset usando pandas

```
df = pd.read_csv('Data_Base.csv',encoding =
    'ISO-8859-1')

df.head()
```

verificamos então que a tabela encontra-se sem informação com relação aos atributos ou até mesmo em relação à classe. Levantar suposição com base nos dados contidos no Data Frame.

```
In [5]: DF.head()
Out[5]:
   182351688  2018-01-02T00:00:00  1  2018  D8  354916128  ...  B                    Cana  Venda Bruta 431.41131292320006  140738.00750943169 326.2269748
0  182452212  2018-01-04T00:00:00  1  2018  D9  354914539  ...  A                    Soja  Venda Bruta         143.803771          9523.271841   66.224076
1  183769629  2018-01-08T00:00:00  1  2018  D9  354914637  ...  C                    Soja  Venda Bruta          17.256453           588.312615   34.092327
2  183757146  2018-01-09T00:00:00  1  2018  D8  354915778  ...  B                  Batata  Venda Bruta          11.983648          1054.273963   87.976049
3  183771027  2018-01-10T00:00:00  1  2018  D8  354916121  ...  B                    Cana  Venda Bruta          57.521508         23002.341012  399.891130
4  183743145  2018-01-10T00:00:00  1  2018  D9  354915757  ...  A  [Cultura Não Encontrada]  Venda Bruta         599.182379         65097.633939  108.644106

[5 rows x 19 columns]
```

Definir nome aos atributos para realizar a análise:

```
#



colunas = ['ID', 'Data/Hora Dia',  'Mês',
    'Ano', 'D#', 'Código', 'Código 2',
    'Código 3', 'Tipo de venda', 'UF',
    'Código 4', 'Família', 'Produto 1',
    'ABC',  'Produto 2', 'Venda Bruta col',
    'Venda Bruta 1', 'Venda Bruta 2',
    'Venda Bruta 3']

df = pd.read_csv('Data_Base.csv',names=colunas,
encoding = 'ISO-8859-1')
```

- Transformar segundo atributo no formato datetime;
- Remover atributos que são invariantes;
- Analisar uma visualização dos dados a partir da matriz de correlação;
- Analisar o plot dos pares;

```
YmdHM = (lambda x: datetime.strptime(x,
        '%Y-%m-%dT%H:%M'))

#Year month day hour minute
#converter coluna em formato datetime

df['Data/Hora Dia'] =
    df['Data/Hora Dia'].apply(YmdHM)

#Verificar quais colunas possuem valores
#que não se repetem e remover

verificar = [len(df.iloc[:,i].value_counts().values)
        for i in range(len(df.columns.values))]

unit, index = -1, []
for i in verificar:
        unit+=1
        print('verificando {}'.format(colunas[unit]))
```

```
            if i==1:
                    index.append(unit)
                    df.drop(colunas[unit], axis=1,
                    inplace=True)
                    print('Coluna {} removida'
                    .format(colunas[unit]))
                    #colunas.remove(colunas[unit])

for i in index:
        colunas.remove(colunas[i])

#remover 'Mês'
colunas.remove('Mês')

df.drop('Mês', inplace=True, axis=1)
```

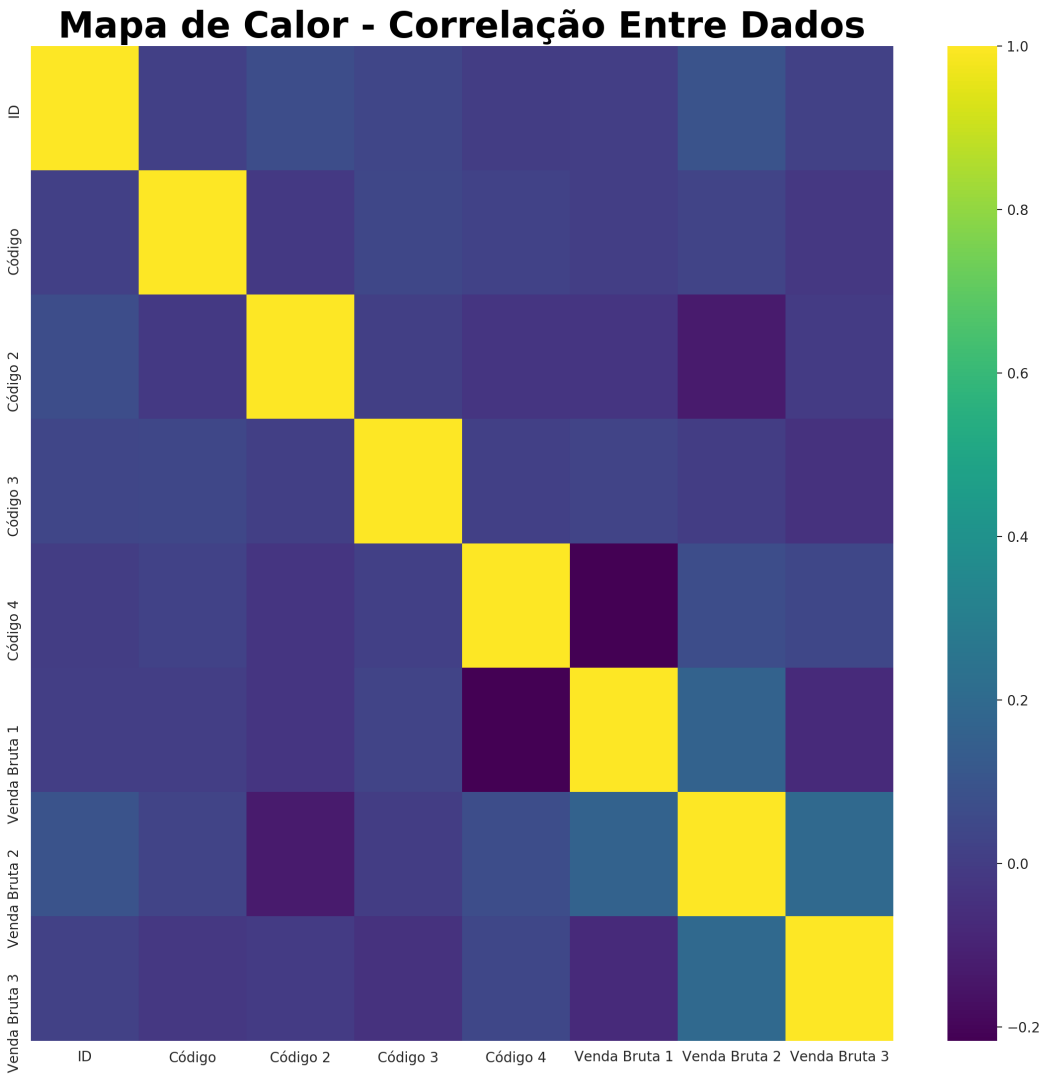

Figura: Atributos não estão fortemente correlacionados;

Figura: Consequência da correlação fraca

- Remover dados irrelevantes para o aprendizado, como o ID;
- Preparação para realizar a Codificação de Categorias (Categorical Encoding):
  - Alguns algoritmos do Python não conseguem ler dados categóricos;
  - Associar itens categóricos a dados numéricos;
  - Disponível apenas na v2 do programa.
  - Ambas versões estão no GitHub.
- Box plot para verificar outliers;
- Os mesmos passos são tomados no segundo versionamento do programa;

```
df3 = df.drop(['ID', 'D#', 'Código',
    'Código 2', 'Código 3','Código 4'],axis=1)

#Remover outliers em atributos categóricos
#(os que só aparecem uma vez ou são desconhecidos)

df3=df3[df3['Produto 1'].apply(lambda x:
    x!= df3['Produto 1'].max())]

df3 = df3[df3['Tipo de venda'].apply(lambda x:
    x!='[Gr.Cliente Não Encontrado]')]

df3 = df3[df3['Produto 2'].apply(lambda x:
    False if x=='[Cultura Não Encontrada]'
    else (False if x=='[Cultura Não Especificada]'
    else True))]

df3 = df3[df3['Produto 1'].apply(lambda x:
    x!='[Gr Segmento Não Encontrado]')]
```

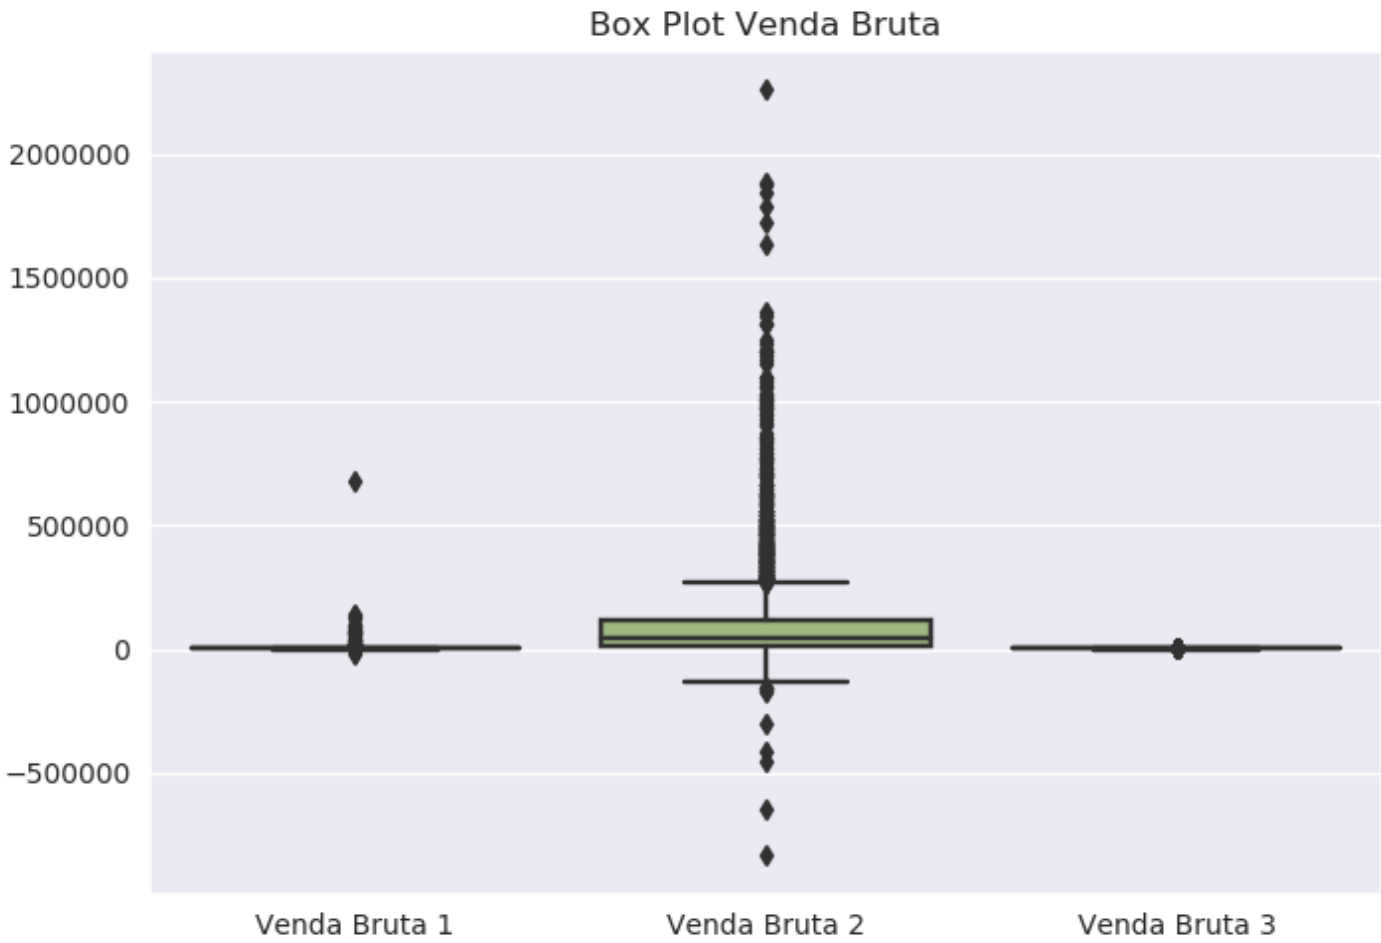
Box Plot Venda Bruta
2000000
1500000
1000000
500000
0
−500000
Venda Bruta 1
Venda Bruta 2
Venda Bruta 3

```
#
#
#

df3 = df3[df3['Venda Bruta 1'] !=
    df3['Venda Bruta 1'].max()]

df3 = df3[df3['Venda Bruta 2'] !=
    df3['Venda Bruta 2'].max()]

df3 = df3[df3['Venda Bruta 2'] !=
    df3['Venda Bruta 2'].min()]

df3 = df3[df3['Venda Bruta 2']  !=
    df3['Venda Bruta 2'].min()]

#recriar coluna de mês e outra do dia, o ano não
#todas as instâncias ocorrem no mesmo ano.
```

```
df3['Mês'] = df3['Data/Hora Dia'].apply(lambda x:
    x.month)

df3['Dia'] = df3['Data/Hora Dia'].apply(lambda x:
    x.day)

#remover atributo do tipo datetime
#algoritmo não lê.

#remover data hora dia
df3.drop('Data/Hora Dia',axis=1,inplace=True)
```

- Problema na coluna ABC, alguma das entradas não é um str, devemos remover essa entrada para realizar o label encoder;
- Classe d3info criada para verificar a variedade dos atributos e possivelmente aplicar one hot encoder.

```
#
```

```
df3 = df3[df3['ABC'].apply(lambda x:
    False if type(x)!= np.str else True)]

df3info.tipo_venda
df3info.Produto_1
df3info.Produto_2

#tipo_venda possui 4 categorias, os outros mais de 4.
```

```
In [19]: df.head()

Out[19]:
         ID Data/Hora Dia  D#     Código     Código 2  Código 3  ...   Produto 1 ABC  Produto 2 Venda Bruta 1  Venda Bruta 2 Venda Bruta 3
0  182351688    2018-01-02  D8  354916128  66711752514   2120550  ...  Inseticida   B       Cana    431.411313  140738.007509    326.226975
1  182452212    2018-01-04  D9  354914539  66711761658   7537440  ...  Inseticida   A       Soja    143.803771    9523.271841     66.224076
2  183769629    2018-01-08  D9  354914637  66711774546   2062314  ...   Outros TS   C       Soja     17.256453     588.312615     34.092327
3  183757146    2018-01-09  D8  354915778  66711782061   3021450  ...   Fungicida   B     Batata     11.983648    1054.273963     87.976049
4  183771027    2018-01-10  D8  354916121  66711791952   2220502  ...  Inseticida   B       Cana     57.521508   23002.341012    399.891130

[5 rows x 16 columns]

In [20]: df3.head()

Out[20]:
  Tipo de venda  UF      Família  Produto 1 ABC Produto 2  Venda Bruta 1  Venda Bruta 2  Venda Bruta 3  Mês  Dia         Lucro
0   Cooperativa  SP   Familia 94  Inseticida   B       Cana     431.411313  140738.007509     326.226975    1    2  141495.645797
1  Venda Direta  MT   Familia 78  Inseticida   A       Soja     143.803771    9523.271841      66.224076    1    4    9733.299688
2  Venda Direta  MA    Familia 3   Outros TS   C       Soja      17.256453     588.312615      34.092327    1    8     639.661395
4   Cooperativa  SP   Familia 94  Inseticida   B       Cana      57.521508   23002.341012     399.891130    1   10   23459.753651
6       Revenda  RJ  Familia 123    Non Crop   A   Non Crop      14.380377    1157.759276      80.509660    1   11    1252.649313
```

Figura: Data Frame tratado x Data frame

- Esse modelo consistirá num diagnóstico de oportunidade de vendas, ele visa otimizar as transações realizadas.
- Dados indicam que a venda bruta total é bem alta;
- Quais condições provocam uma venda bem sucedida (acima da média);
- Suposição:

$$L = \sum_{i=1}^{3} Vl_i$$

  - A classe será o lucro que consiste na soma dos três últimos atributos, que por hipótese, são o lucro líquido produzido pela compra.
- Separar dados previsores dos dados classificadores;
- Realizar o label encoder;

```
#


df3['Lucro'] = df3['Venda Bruta 1']+df3['Venda Bruta
    +df3['Venda Bruta 3']

#classe LabelEncoder do sklearn

labelencoder = LabelEncoder()


#dados previsores:
previsores2 = df3.drop(['Venda Bruta 1',
        'Venda Bruta 2', 'Venda Bruta 3',
        'Lucro'], axis=1).values
```

```
#Label Encoder aos dados categóricos
for n in [1,2,4,3,5]:
  previsores2[:,n] =
        labelencoder.fit_transform(previsores2[:,n])


#One Hot Encoder em tipo de vendas

onehotencoder = make_column_transformer(
    (OneHotEncoder(categories='auto',
    sparse=False),[0]), remainder='passthrough')

X = onehotencoder.fit_transform(previsores2)

#Classe classificada como 0 caso x<mean e 1 x=> mean

classe2 = df3['Lucro'].apply(lambda x:
        0 if x < df3['Lucro'].mean() else 1)
```

- Dividir os dados em dados de treino e teste;
- Modelo treinado com 70% dos dados e testado com 30%;
- Treinar modelo de Naive Bayes Gaussiano e de Floresta Randômica;
- Verificar os dados testados e precisão do modelo;

```
    #

    X_treino2, X_teste2, Y_treino2, Y_teste2 = train_

#=========================================
#   NAIVE BAYES GAUSSIANO
#=========================================

#Carregar classe a partir do sklearn

nb2 = GaussianNB()

#Fitar o modelo
nb2.fit(X_treino2,Y_treino2)

#Testar o modelo
prev2 = nb2.predict(X_teste2)
```

```
#Taxas de acerto e erro

taxa_acerto2 = (accuracy_score(Y_teste2, prev2))*100
taxa_erro2 = (1 - taxa_acerto2/100)*100

#=======================================
#   FLORESTA RANDOMICA
#=======================================

#Carregar classe a partir do sklearn.ensemble

floresta2 = RandomForestClassifier(n_estimators =
    200)

#n_estimators é o número de árvores de decisão

#ajustar o modelo
floresta2.fit(X_treino2,Y_treino2)
```

```
#testar modelo
previsoes2 = floresta2.predict(X_teste2)
```

- Verificar Taxas de acerto e de erro;
- Criar matriz de confusão do modelo;
  - Métrica voltada para modelos de classificação;
  - Quantidade de FP, FN, VP, VN;
  - Acurácia e sensibilidade;

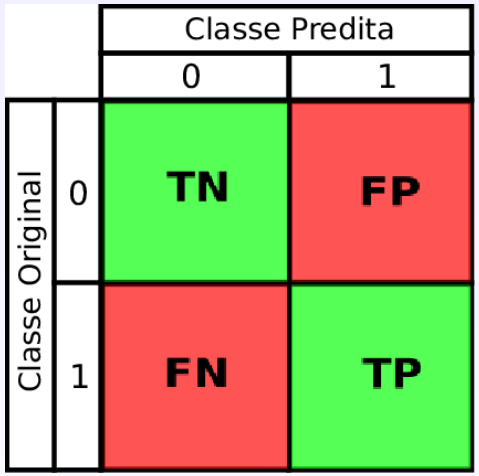

Figura: Tabela de Confusão

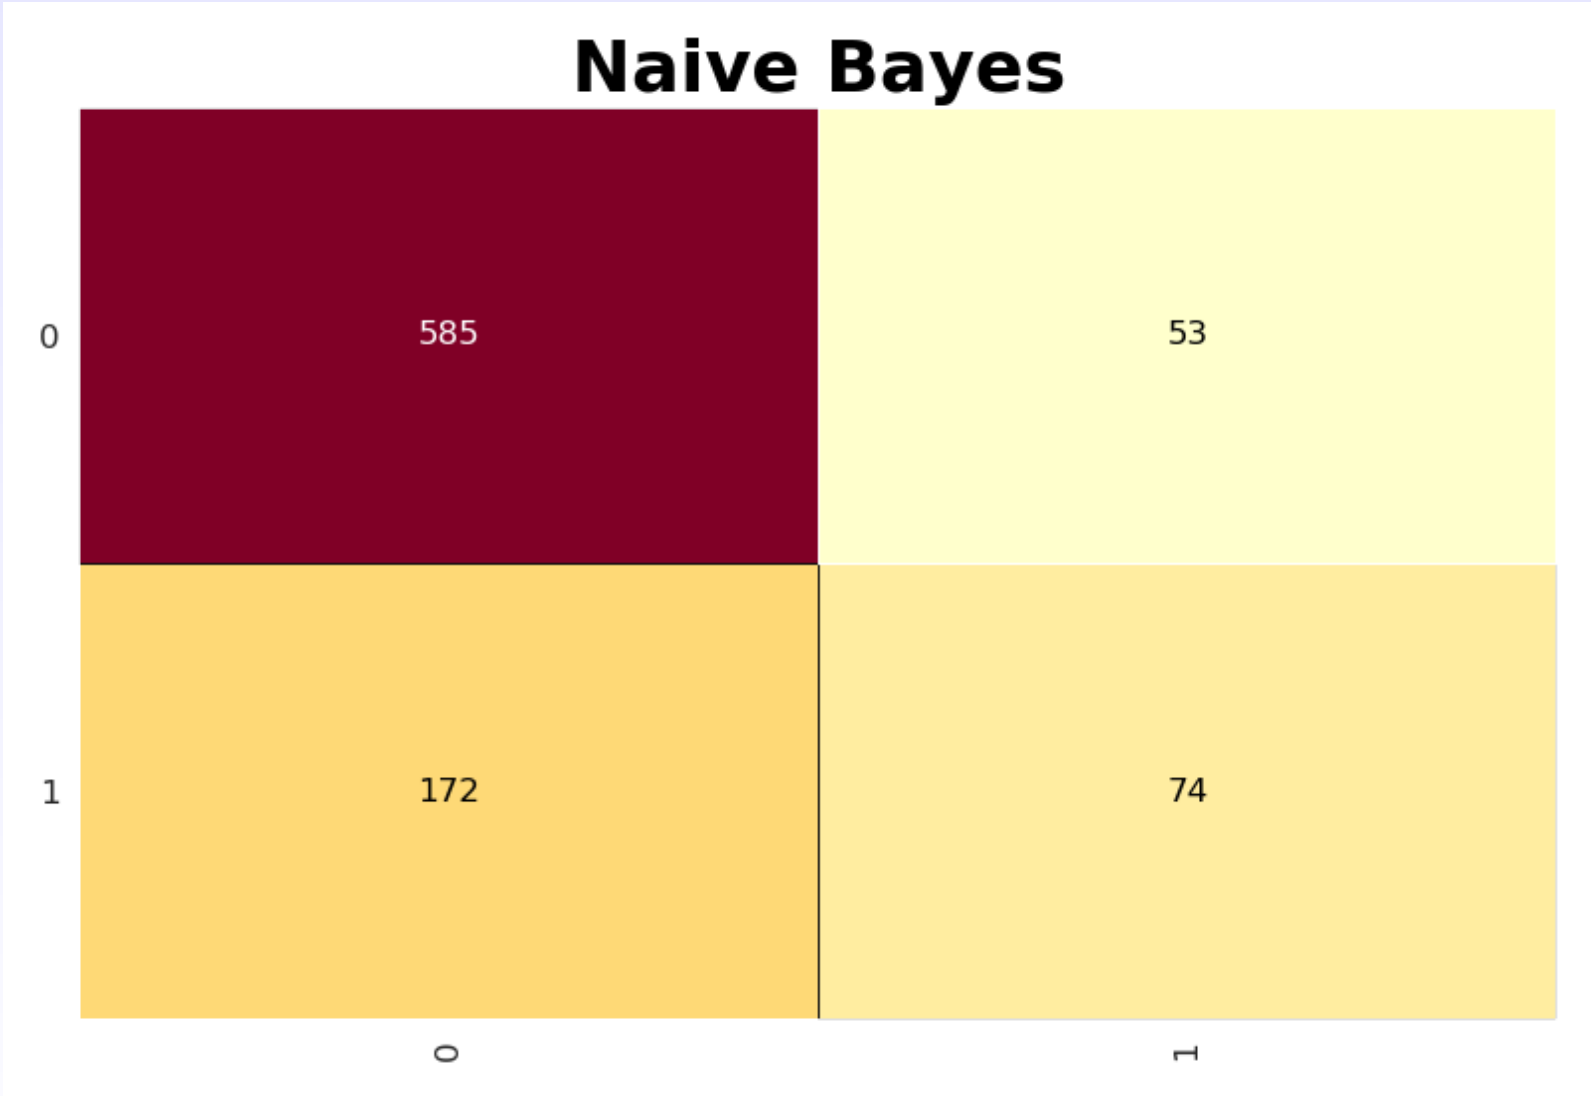

Figura: Naive Bayes

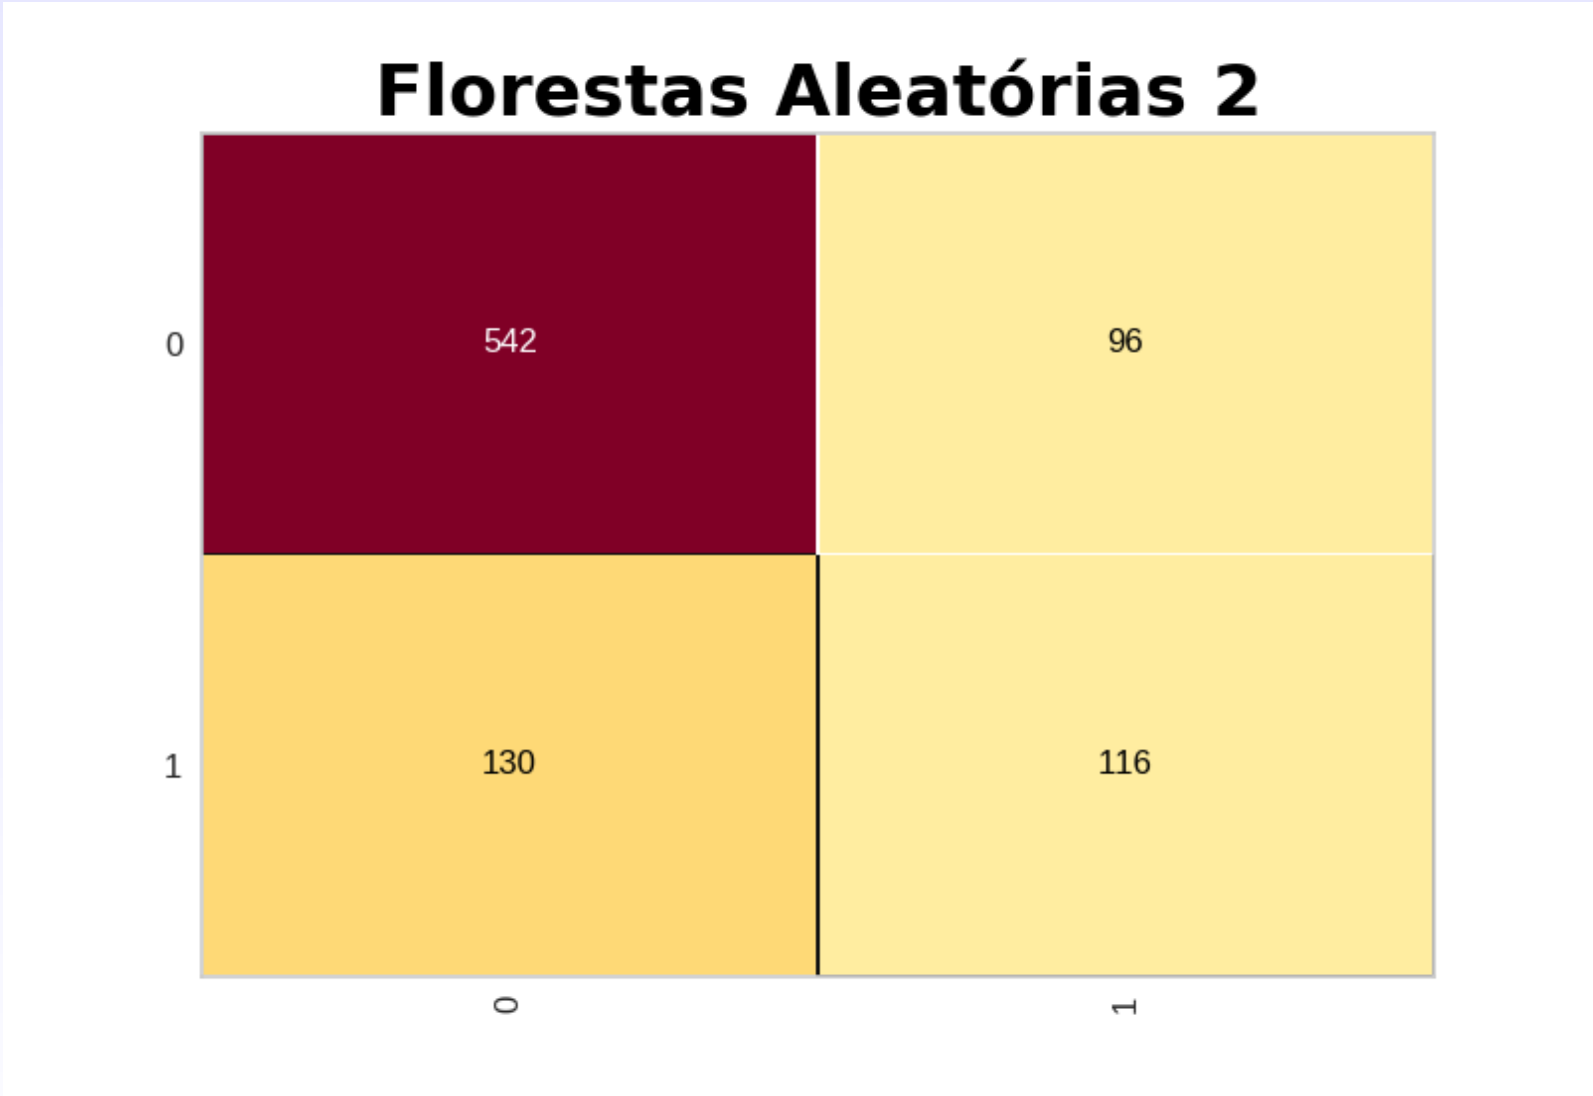

Figura: Naive Bayes

O modelo foi fitado com sucesso e apresentou as seguintes taxas:

Modelo	Taxa de acerto	Taxa de erro
Naive Bayes	74,55%	25,45%
Ensemble	74,77%	25,23%

As taxas da tabela acima implicam que o modelo foi bem treinado, mas levando em conta as hipóteses que foram tomadas. Obtendo acesso à mais informações sobre a lista, pode ser necessário recorrer a outros modelos de aprendizado.

O modelo pode ser otimizado levando em conta os valores reais dos atributos que não foram informados e tomando considerações reais sobre os valores do lucro bruto que não pode ser contabilizada devido à falta de informação

Projeto disponível no github

`https://github.com/acidbutter96/diagnostico-oportunidades/`

Lucas Ferreira, Murilo Gazzola, Deborah Ferrari, Marina Zupelari, Paula Paiva, and Jose Rodrigues Jr. Métodos de classificação aplicados à detecção automática de estilos de aprendizagem em um ambiente real de ensino. In *Brazilian Symposium on Computers in Education (Simpósio Brasileiro de Informática na Educação-SBIE)*, volume 28, page 1517, 2017.

F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.